SCX 5002 · SISTEMAS COMPLEXOS I · USP EACH

Linguagem como sistema complexo

Previsibilidade, lei de Zipf e emergência: o que os romances de Machado de Assis mostram sobre os grandes modelos de linguagem



Hercules Ramos

Nº USP 18006184

Seminário · EACH, Escola de Artes, Ciências e Humanidades

ROTEIRO · CERCA DE 19 MINUTOS

Uma pergunta, três ideias

A PERGUNTA

O ”salto” de desempenho dos grandes modelos de linguagem é uma transição de fase ou um efeito da régua?

1

Previsibilidade

Quanto do próximo caractere o contexto já decide?

2

Lei de Zipf

O que o expoente das frequências permite concluir?

3

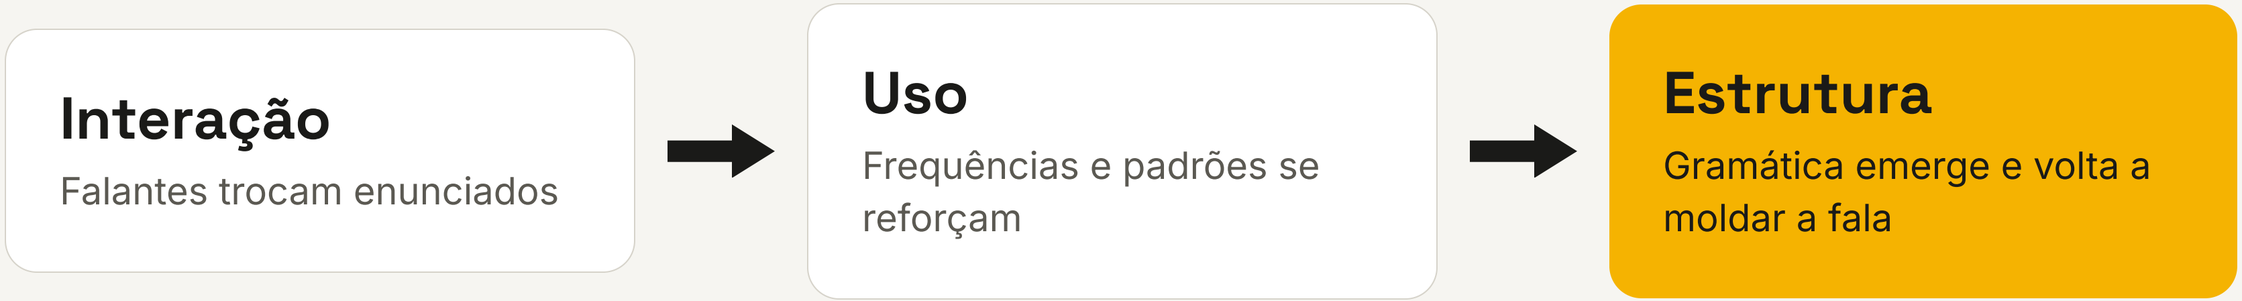
Emergência

O salto aparece no parâmetro de ordem ou só na métrica?

Dados próprios: os dez romances de Machado de Assis (1872 a 1908)

A linguagem é um sistema adaptativo

Ninguém decide sozinho como a língua funciona: muitos falantes interagem, sem controle central, e a estrutura nasce do uso.



Fonte: Beckner et al. (Five Graces Group), Language Learning 59, supl. 1, 2009

ABERTURA · O QUE VOU COMPARAR

Comparar o observável, não o mecanismo

COMPARO: GRANDEZAS MEDIDAS NO TEXTO

- Quanto o contexto reduz a incerteza
- Como as frequências das palavras se distribuem
- Como o desempenho muda com o tamanho do modelo

NÃO SUPONHO

- Que um cérebro e uma rede neural funcionem do mesmo jeito
- Que estatísticas parecidas tenham a mesma causa

Estatísticas iguais podem vir de mecanismos diferentes: a Ideia 2 mostra um exemplo.

ABERTURA · OS DADOS

Do arquivo ao dado: o pré-processamento

1. Ler os 10 romances na codificação original (Latin-1), com acentos
2. Retirar cabeçalhos editoriais, 728 títulos de capítulo e a marca "FIM"
3. Palavras: minúsculas, letras com acento; "diga-me" conta como uma; sem números nem pontuação
4. Caracteres: sem acentos, 26 letras e o espaço, 27 símbolos como em Shannon
5. Validação: treinar em 9 romances e testar no 10º, repetindo 10 vezes

525.067

palavras, 31.243 distintas

2,9 milhões

de caracteres (27 símbolos)

1872 a 1908

de Ressurreição a Memorial de Aires

Machado de Assis, Obra Completa, Nova Aguilar, 1994 · corpus machado do NLTK · processamento próprio em Python

IDEIA 1 · PREVISIBILIDADE

Entropia como jogo de sim ou não

Alguém esconde a próxima letra de um texto. Quantas perguntas de sim ou não você precisa, em média, para descobri-la? Esse número é a entropia, medida em bits.

EXEMPLO

pens_

Depois de "pens", a próxima letra é quase sempre "a": quase nenhuma pergunta.

4,75

sem saber nada: 27 símbolos igualmente prováveis

3,93

sabendo só quais letras são mais comuns em Machado

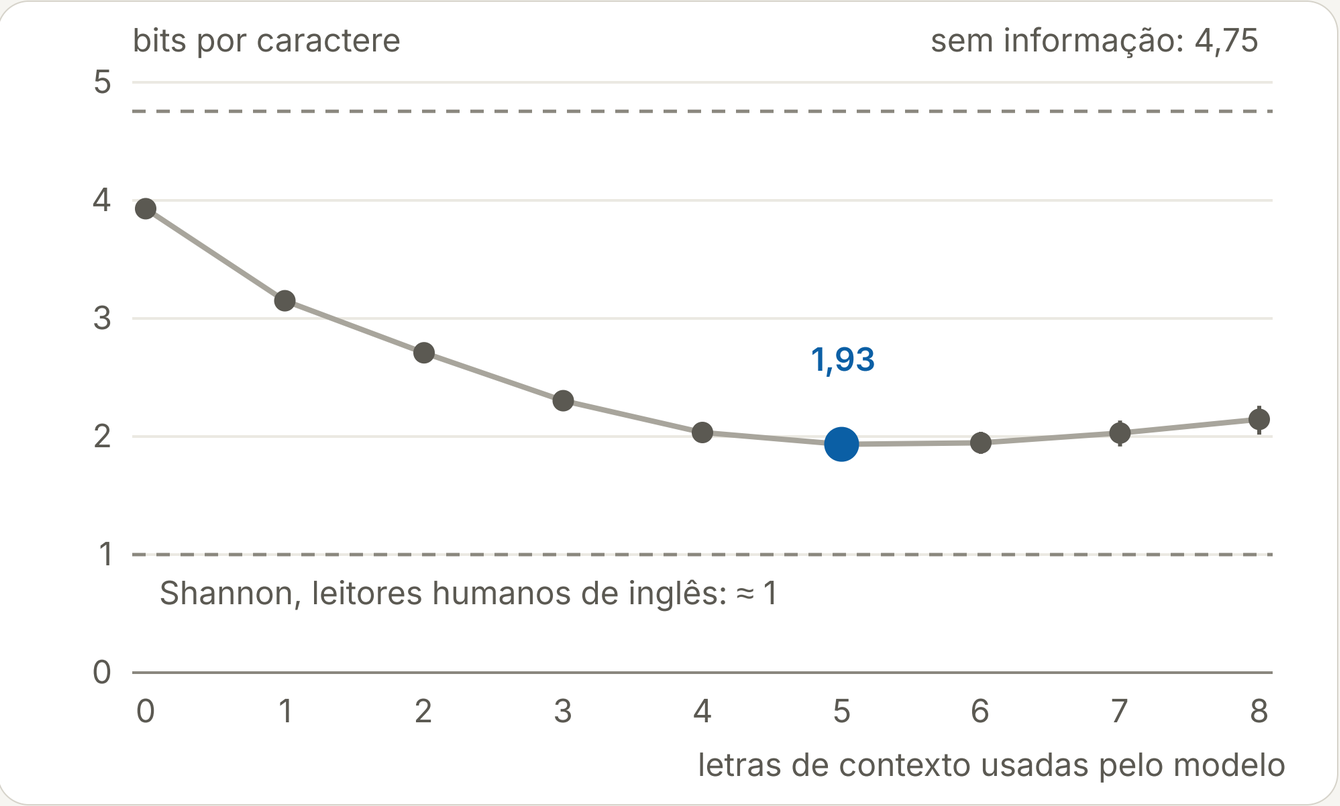
?

sabendo também as letras anteriores: próximo slide

1 bit = uma pergunta de sim ou não bem escolhida · base: Shannon (1951) e Unidade 4 (Informação)

IDEIA 1 · PREVISIBILIDADE · DADOS PRÓPRIOS

Com 5 letras de contexto: 1,93 bit



1,86 a 2,01

variação entre os 10 romances de teste, com 5 letras de contexto

≥ 59%

do texto é redundante, já decidido pela estrutura da língua

Com mais de 5 letras, piora: faltam dados para combinações tão longas.

Cálculo próprio: n-gramas de caracteres, treino em 9 romances e teste no 10º · barras = menor e maior valor

IDEIA 1 · PREVISIBILIDADE · LIGAÇÃO COM OS LLMS

Do jogo de Shannon ao treino de LLMs

1951 · SHANNON

Uma pessoa adivinha a próxima letra

Ela conhece o texto anterior. O número de tentativas até acertar permite estimar a entropia da língua.

=

HOJE · MODELOS DE LINGUAGEM

Um modelo prevê o próximo token

Ele vê os tokens anteriores. O treino minimiza a entropia cruzada entre a previsão e o texto real.

A mesma tarefa, não o mesmo mecanismo: o que se compara é o número de bits, não o modo de prever.

Fonte: Shannon, Bell System Technical Journal 30(1), 1951

IDEIA 2 · LEI DE ZIPF

Poucas palavras comuns, muitas raras

Quando a posição no ranking multiplica por 10, a frequência se divide por cerca de 10: da posição 100 (568 vezes) para a 1.000 (56 vezes).

Ou seja: **posição × frequência ≈ constante**. Isso é uma lei de potência, com expoente α ≈ 1.

17,4%
do texto são 5 palavras: a, que, de, e, o

46,9%
das palavras distintas aparecem uma só vez

Posição	Palavra	Vezes	Posição × vezes
10	os	4.857	48.570
50	nada	1.080	54.000
100	pela	568	56.800
500	houve	118	59.000
1.000	confesso	56	56.000

Nas pontas a regra falha um pouco. Por isso o valor de α depende de qual faixa se usa: próximo slide.

Cálculo próprio · 525.067 palavras dos dez romances · Zipf (1936, 1949)

Quanto vale α? Depende de como se mede

Método	Dados usados	α estimado
Reta em escala log-log	posições 1 a 100	0,97
Reta em escala log-log	posições 10 a 1.000	0,99
Reta em escala log-log	posições 10 a 5.000	1,04 (IC 95%: 1,037 a 1,041)
Reta em escala log-log	posições 100 a 10.000	1,14
Máxima verossimilhança	725 palavras com 82+ ocorrências	1,00 (IC 95%: 0,99 a 1,02)
Um romance por vez	posições 10 a 1.000	0,99 a 1,04

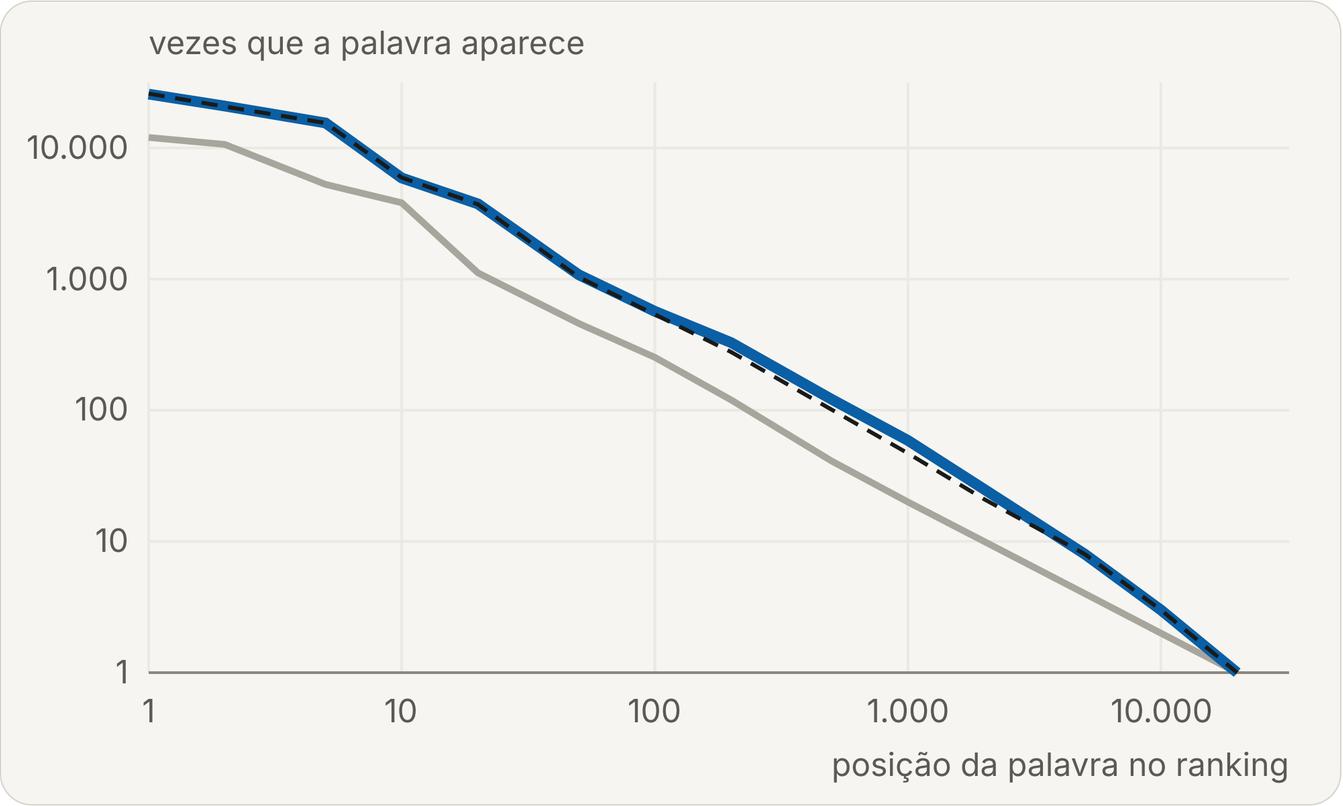
± 0,02 incerteza estatística (500 reamostragens)

0,97 a 1,14 variação conforme o método: a maior fonte de incerteza

Cálculo próprio · máxima verossimilhança: Clauset, Shalizi e Newman, SIAM Review 51(4), 2009

IDEIA 2 · LEI DE ZIPF · O QUE A ≈ 1 NÃO PROVA

Até um texto aleatório segue Zipf



Machado de Assis

α = 1,04

------ Texto gerado por n-gramas

α = 1,07

79% das suas "palavras" não existem

Digitação aleatória

α = 1,05

letras sorteadas, sem gramática nem sentido

Cálculo próprio · três textos de 2,9 milhões de caracteres (27 símbolos) · α nas posições 10 a 5.000 · Miller (1957)

IDEIA 3 · EMERGÊNCIA

Habilidades que ”surgem” com a escala

Wei et al. (2022): uma habilidade é emergente se está ausente nos modelos menores e presente nos maiores. Abaixo de certo tamanho, desempenho de chute.

13 bi	somar números de 3 dígitos (GPT-3)
175 bi	somar números de 4 e 5 dígitos (GPT-3)
540 bi	Word in Context, sentido de palavras (PaLM)

bi = bilhões de parâmetros

A CRÍTICA · SCHAEFFER ET AL. (2023)

As habilidades "emergentes" aparecem em métricas de tudo ou nada, como o **acerto exato**: só conta a resposta inteira certa.

acerto ≈ p^L

Se cada símbolo sai certo com chance p, uma resposta de L símbolos sai inteira certa com chance p elevado a L.

Fontes: Wei et al., TMLR 2022, Tabela 1 · Schaeffer, Miranda e Koyejo, NeurIPS 2023

IDEIA 3 · EMERGÊNCIA · DEFINIÇÕES

Definindo o parâmetro de ordem

Elemento	Neste trabalho	No modelo de Ising
Sistema	Modelos que preveem a próxima letra olhando as k anteriores (k de 0 a 8)	Ímãs numa rede
Variável de controle	Tamanho do modelo: número de parâmetros, de 27 a 2,7 milhões	Temperatura
Parâmetro de ordem φ	Fração das letras do romance de teste que o modelo acerta	Magnetização
Métrica de tarefa	Acerto exato: fração das vezes em que acerta L letras seguidas, ≈ φ^L	Uma função não linear da magnetização

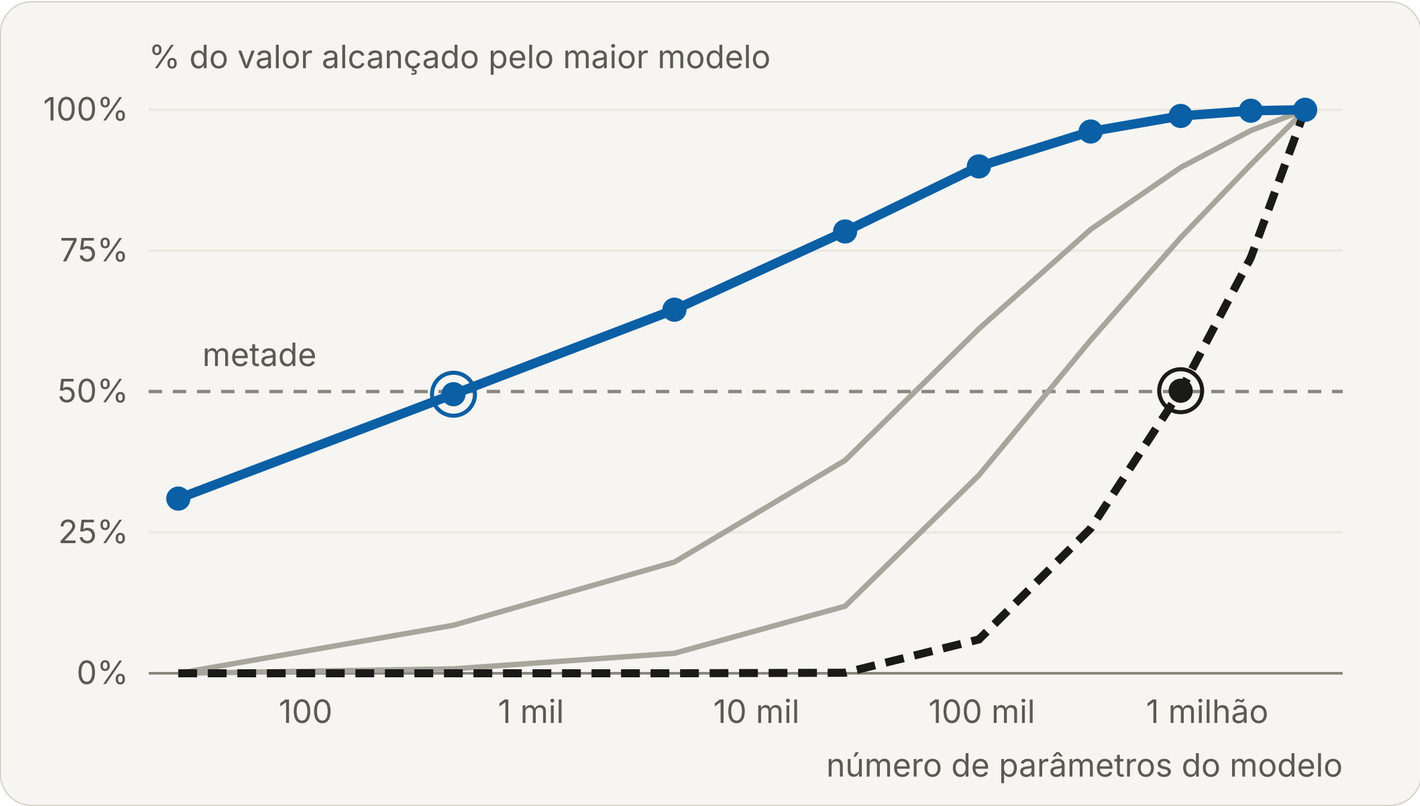
CRITÉRIO DE TRANSIÇÃO

Haveria transição se o próprio φ mudasse de repente num tamanho crítico, com a taxa de variação dφ/d(log tamanho) crescendo sem limite ali.

Base: Solé, Phase Transitions, 2011 (parâmetro de ordem e suscetibilidade)

IDEIA 3 · EMERGÊNCIA · DADOS PRÓPRIOS

O salto só aparece no acerto exato



acerto por letra, φ

de 18% a 59,5%; metade do ganho com ~450 parâmetros

3 e 5 letras seguidas

no maior modelo: 23,8% e 9,1%

10 letras seguidas

zero até 25 mil parâmetros; metade só com ~760 mil; máximo 0,7%

0,12

máximo de dφ/d(log tamanho), largo: sem ponto crítico

Cálculo próprio · média de 10 rodadas (treino em 9 romances, teste no 10º)

IDEIA 3 · EMERGÊNCIA · LEITURA

O salto está na régua, não no sistema

PARÂMETRO DE ORDEM

φ cresce de forma suave e satura. Não há ponto crítico: é uma passagem gradual.

MÉTRICA DE TAREFA

O acerto exato salta porque vale cerca de φ^L: o salto vem da régua.

PARA UM LLM

Uma transição teria de aparecer num parâmetro contínuo e ficar mais abrupta com o tamanho do sistema.

Limite: um modelo de n-gramas não é um LLM. O experimento mostra o efeito da métrica, não que toda emergência seja ilusória.

Base: Solé (2011); Schaeffer, Miranda e Koyejo (2023)

CONCLUSÃO

Três ideias para levar

1 **Previsibilidade.** Com 5 letras de contexto, Machado custa 1,93 bit por letra, contra 4,75 sem informação: pelo menos 59% do texto é redundante.

2 **Lei de Zipf.** $\alpha = 1{,}0 \pm 0{,}1$, conforme o método. Um texto aleatório também dá $\alpha \approx 1$: o expoente não revela o mecanismo.

3 **Emergência.** Com um parâmetro de ordem definido, o salto aparece só na métrica de acerto exato. Emergência em LLMs é uma hipótese a testar.

Limites: um autor, modelos simples, uma variável de controle. Detalhes no artigo.

REFERÊNCIAS

Fontes do seminário

BECKNER, C. et al. (Five Graces Group). Language is a complex adaptive system. *Language Learning*, v. 59, supl. 1, 2009.

PIANTADOSI, S. T. Zipf's word frequency law in natural language. *Psychonomic Bulletin & Review*, v. 21, 2014.

MILLER, G. A. Some effects of intermittent silence. *The American Journal of Psychology*, v. 70, n. 2, 1957.

WEI, J. et al. Emergent abilities of large language models. *TMLR*, 2022.

SOLÉ, R. V. *Phase Transitions*. Princeton University Press, 2011.

SHANNON, C. E. Prediction and entropy of printed English. *Bell System Technical Journal*, v. 30, n. 1, 1951.

CLAUSET, A.; SHALIZI, C. R.; NEWMAN, M. E. J. Power-law distributions in empirical data. *SIAM Review*, v. 51, n. 4, 2009.

WITTEN, I. H.; BELL, T. C. The zero-frequency problem. *IEEE Transactions on Information Theory*, v. 37, n. 4, 1991.

SCHAEFFER, R.; MIRANDA, B.; KOYEJO, S. Are emergent abilities of LLMs a mirage? *NeurIPS*, 2023.

MACHADO DE ASSIS. *Obra Completa*. Nova Aguilar, 1994 (corpus machado, NLTK).

SCX 5002 · SISTEMAS COMPLEXOS I · USP EACH

Obrigado.

Métodos, dados e resultados completos no artigo que acompanha este vídeo

Hercules Ramos

linkedin.com/in/hercules-ramos